

母崇徐 - AI应用开发工程师

男 / 22岁
17628876799
3220290868@qq.com
<https://github.com/mcxxxxxcm>



教育背景

西昌学院 - 计算机科学与技术 2022.09 - 2026.06

- 主修课程：数据结构与算法、数据库原理、操作系统、Python程序设计、软件工程、Linux系统实训。
- 荣誉奖项：第十五届蓝桥杯大赛省二等奖、校级奖学金三等奖、公益服务先进个人、大学英语六级。

项目

智能医疗Agent

LangChain RAG PostgreSQL Chroma Redis GPT-4o

- 项目描述：**
针对医疗咨询场景对准确性高要求，基于 LangGraph和RAG构建的智能问诊Agent。系统集成了混合检索、多轮对话记忆、流式输出及安全护栏，旨在提供专业、可追溯的医疗建议。
- 技术亮点：**
 - 构建 Agentic RAG 工作流：**基于 LangGraph 设计有状态的多节点工作流（State Graph），实现了“记忆加载 -> 意图识别 -> 查询重写 -> 混合检索 -> 重排序 -> 答案生成 -> 安全审查”的闭环流程。规范化了医疗问诊的流程。
 - 高精度混合检索策略：**设计向量 + 关键词 + 重排序 的三级检索架构，将专业术语匹配率从65%提高到了92%，解决了通用模型不懂专业属于的痛点。使用RRF合并去重对混合检索的文档进行初筛，集成 bge-reranker-v2-m3 模型对初筛结果进行精排，提升医疗专业术语的匹配准确率近40%。
 - 分层缓存：**构建 Redis精确匹配 + 语义相似性缓存的双层缓存机制，响应速度提升200%，高频问题命中率达 60%+，大幅降低Token消耗与API成本，提高了用户体验。
 - 上下文管理：**设计“短期记忆 + 滑动窗口 + 长期记忆”三层架构。基于 PostgresSaver 实现对话状态持久化与会话隔离，支持服务重启后恢复对话；设计“阈值触发 + LLM增量摘要”机制，当对话超过14轮时自动压缩早期对话，有效控制上下文窗口在 4K tokens 以内；基于 PostgresStore 构建用户画像存储，自动提取病史与过敏史信息，支持跨会话个性化医疗建议。
 - RAG 系统质量评估：**基于 RAGAS 框架构建自动化评估体系，实现四维指标量化分析（忠实度、答案相关性、上下文精确度、上下文相关性），极大地提升了文档可信度。

数据分析助手

langchain text2sql PostgreSQL glm-4

- 项目描述：**
基于 LangChain create_agent 构建的智能数据分析助手，支持自然语言转 SQL 查询、安全数据操作、多轮对话及动态可视化，显著降低非技术用户的数据分析门槛。
- 技术亮点：**
 - Token优化：**通过简化 System Prompt、精简工具描述、引入 trim_messages 中间件裁剪历史消息，将单次请求 Token 消耗从 23,000 降至 3,800（节省 83%），大幅降低 API 成本。
 - 可人工干预：**集成 Human-in-the-Loop (HITL) 人工审核中间件，对 INSERT/UPDATE/DELETE 操作进行安全拦截。经人工审核后才能继续执行。
 - 数据可视化：**支持图表生成，基于用户请求动态选择柱状图、折线图或饼图，RestrictedPython 沙箱安全执行绘图代码，返回 Base64 图像。

技能

- LLM 应用开发：**深入理解 LangChain/LangGraph 框架，具备 Agentic RAG 架构设计经验；熟悉 Prompt Engineering 及多轮对话状态管理；掌握LLM上下文管理策略。
- 后端开发：**熟练使用 Python (Async/Await) 及 FastAPI 构建高性能异步API；熟悉 SSE 流式响应实现。
- 检索与向量技术：**掌握 Hybrid Retrieval (混合检索) 策略；熟练使用 Chroma/Milvus 向量数据库；有 BGE-Reranker 重排序模型落地经验。
- 数据库：**熟练使用 PostgreSQL、Mysql、Redis及常见的优化手段。
- 工具：**熟悉Git进行版本控制；掌握现代 Python 工具链 uv 实现极速依赖管理与项目构建；熟悉 Docker 容器化部署；